


# Trabalho Final: Projeto de Data Science

## 1. Objetivo

O objetivo deste trabalho é aplicar de forma prática e integrada os conceitos, técnicas e ferramentas de Data Science estudados ao longo da disciplina. Vocês desenvolverão um projeto completo, desde a formulação de um problema até a análise e comunicação dos resultados, seguindo um fluxo de trabalho estruturado.

## 2. O Workflow do Projeto

Todo o projeto deverá seguir as etapas essenciais de um ciclo de vida de Data Science. Embora a ordem possa ter alguma flexibilidade, as seguintes fases devem ser contempladas e documentadas:



1. **Definição do Problema e Coleta de Dados:** Entender o problema de negócio ou a questão de pesquisa. Coletar ou selecionar os dados necessários para a análise.
2. **Análise Exploratória de Dados (EDA):** Investigar o dataset para descobrir padrões, anomalias, formular e testar hipóteses iniciais, e verificar suposições com o auxílio de estatísticas e visualizações.
3. **Preparação e Limpeza dos Dados:** Realizar a limpeza (tratamento de valores ausentes, outliers), transformação (normalização, padronização) e engenharia de features para preparar os dados para a modelagem.

4. **Modelagem:** Selecionar, treinar e avaliar diferentes algoritmos de Machine Learning ou modelos estatísticos que sejam adequados para resolver o problema proposto.
5. **Avaliação dos Resultados:** Interpretar os resultados dos modelos, avaliar sua performance com métricas apropriadas e analisar sua relevância para o problema original.
6. **Comunicação:** Documentar e apresentar as conclusões de forma clara e objetiva no relatório final.

### 3. Instruções Gerais

- **Tema:** O tema do projeto é de livre escolha. Recomendo que escolham um assunto de seu interesse, pois isso torna o trabalho mais motivador. Vocês podem buscar **inspiração** e datasets em plataformas como [Kaggle](#), [UCI Machine Learning Repository](#) ou portais de dados governamentais.
- **Ferramentas:** O projeto deverá ser desenvolvido em **R** ou **Python**, utilizando as bibliotecas e frameworks apresentados em aula (ex: Pandas, Scikit-learn, Matplotlib, Tidyverse, Caret, etc.).
- **Formato:** O trabalho poderá ser realizado **individualmente ou em grupos de até 4 integrantes**.

### 4. Entregáveis

O projeto será composto por três entregáveis obrigatórios: um repositório no GitHub, um relatório técnico em PDF e um dashboard interativo.

#### 4.1. Repositório no GitHub

- Os arquivos do projeto (código-fonte, notebooks, etc.) devem estar no GitHub (o repositório pode ser privado mas me deem acesso – meu user GitHub é [holbig@upf.br](mailto:holbig@upf.br)).
- O repositório deve ser bem organizado, contendo um arquivo **README.md** que descreva o projeto, como executar o código e quaisquer outras informações relevantes.
- O código deve ser limpo, comentado e reproduzível.

#### 4.2. Relatório Técnico

- Um relatório técnico sobre o projeto deverá ser elaborado utilizando ferramentas baseadas em Markdown, como **R Markdown** ou **Jupyter Notebook/Quarto**, e exportado para PDF.
- O relatório é o documento principal para a avaliação do projeto e deve conter, no mínimo, os seguintes tópicos:
  - **Título e Autores.**

- **Introdução:** Apresentação do tema, relevância, o problema que o projeto busca resolver e as principais questões ou hipóteses iniciais que nortearam o trabalho.
- **URL do Repositório no GitHub.**
- **Dataset:** Descrição detalhada dos dados utilizados. Inclua a origem, o dicionário de variáveis, as principais características e todas as etapas de limpeza, transformação e engenharia de features realizadas.
- **Análise Exploratória:** Apresentação das principais descobertas. Inclua as hipóteses que guiaram a sua análise, os gráficos e as estatísticas descritivas utilizadas para investigá-las e as conclusões que justificaram as decisões tomadas.
- **Modelagem:** Descrição dos modelos e algoritmos utilizados, justificando a escolha de cada um. Detalhe como os modelos foram treinados e validados.
- **Resultados e Discussão:** Apresentação das métricas de performance dos modelos. Analise e compare os resultados, interpretando o que eles significam no contexto do problema.
- **Conclusão:** Resumo do trabalho realizado, discussão sobre as limitações encontradas e sugestões para trabalhos futuros.

### 4.3. Dashboard Interativo

- Além do relatório escrito, vocês deverão construir um dashboard interativo para apresentar os principais resultados e insights do projeto de forma visual e dinâmica.
- O dashboard deve permitir que o usuário explore os dados ou os resultados do modelo de maneira interativa (ex: aplicando filtros, selecionando variáveis, etc.).
- **Ferramentas Sugeridas:** A escolha da ferramenta é livre, mas recomendamos o uso de bibliotecas como **Streamlit** ou **Dash** para Python, ou **Shiny** para R.
- O link para acessar o dashboard (se estiver online) ou as instruções para executá-lo localmente devem estar claramente indicados no arquivo **README .md** do repositório.

## 5. Prazo e Submissão

- **Data Limite para entrega do Relatório:** A submissão do relatório PDF deverá ser realizada até o dia **16 de junho de 2026**.
- **Formato de Submissão:** O relatório final, em formato **PDF**, deve ser submetido na plataforma Moodle, na área correspondente à atividade.

## 6. Apresentação Oral

- **Obrigatoriedade:** A apresentação oral do trabalho é uma etapa **obrigatória** e um pré-requisito para a avaliação final do projeto.
- **Datas:** As apresentações serão realizadas no dia **16 de junho**. A ordem será definida e comunicada posteriormente.
- **Formato:** Cada equipe terá um tempo de **5 minutos** para apresentar o projeto, seguido por uma sessão de perguntas. A apresentação deve incluir:

- Uma visão geral do problema e dos objetivos.
- Uma demonstração ao vivo do dashboard interativo.
- Apresentação dos principais resultados, conclusões e dificuldades encontradas.

## 7. Critérios de Avaliação

O projeto será avaliado com base na qualidade dos entregáveis, e o desempenho na apresentação oral será considerado na avaliação geral do domínio sobre o projeto. A pontuação será distribuída da seguinte forma:

- **Qualidade do Código e Repositório (15%):** Organização, clareza, comentários e reprodutibilidade do código.
- **Análise Exploratória e Preparação dos Dados (25%):** Profundidade da análise, qualidade das visualizações e justificativa das etapas de pré-processamento.
- **Modelagem e Avaliação (25%):** Escolha apropriada dos modelos, correção na aplicação das técnicas e análise crítica das métricas de performance.
- **Qualidade do Relatório Técnico (15%):** Clareza na comunicação escrita, estrutura lógica, coesão e capacidade de interpretar e discutir os resultados.
- **Dashboard Interativo (20%):** Qualidade da visualização, interatividade, relevância das informações apresentadas e clareza na comunicação dos resultados.

Bom trabalho a todos! Estou à disposição para tirar dúvidas e orientá-los ao longo do processo.